

Umsatz- und Länderanalyse eines internationalen Online-Shops – Datenintegration & Reporting mit SAP Datasphere und SAP Analytics Cloud

Hausarbeit

im Rahmen des Seminars "Business Intelligence 2"

Sommersemester 2025

Daten ausgeblendet für Github Abgabetermin: 2025-07-21

Inhaltsverzeichnis

1	Einleitung	1
2	Zielsetzung & Leitfragen	2
	2.1 Zielsetzung	
	2.2 Leitfragen	
3	Datenbasis & Angedachtes dimensionales Modell	
4	Methodisches Vorgehen	5
	4.1 Datenimport & Staging	
	4.2 Staging-Area	8
	4.3 Modellierung der Dimensionen	9
	4.4 Fakten-View	11
	4.5 Kennzahlen & Filter-Variabeln	12
	4.6 Story-Erstellung in SAP Analytics Cloud	14
5	Fazit	17

1 Einleitung

Der Online-Handel wächst kontinuierlich und erzeugt täglich riesige Mengen an Transaktionsdaten. Damit Unternehmen aus diesen Rohdaten zeitnah belastbare Entscheidungen ableiten können, benötigen sie eine skalierbare, cloudbasierte Analyseumgebung. Herkömmliche On-Premise-Data-Warehouse-Lösungen stoßen dabei häufig an Grenzen: Sie sind schwerfällig zu erweitern, benötigen hohe Administrationsaufwände und binden Datenquellen oft nur mit erheblichem Verzögerungsaufwand ein.¹

In dieser Arbeit wird daher exemplarisch gezeigt, wie ein frei verfügbarer E-Commerce-Datensatz aus Kaggle ("E-commerce Data") mithilfe von **SAP Datasphere** in ein konsistentes Cloud-Data-Warehouse überführt und anschließend in **SAP Analytics Cloud** (**SAC**) interaktiv ausgewertet werden kann. Nach der Datenbereinigung und dem Upload werden dafür zunächst zentrale Dimensionen wie Produkt, Kunde und Zeit modelliert und mit den Verkaufsfakten verknüpft.² Auf Basis dieses Analytic Models werden anschließend Kennzahlen wie Gesamtumsatz, durchschnittlicher Warenkorbwert sowie ein Länder- und Zeitvergleich abgeleitet und in einem SAC-Dashboard visualisiert.

Ziel der Dokumentation ist es, den gesamten End-to-End-Prozess – von der Rohdatei bis zum fertig nutzbaren Management-Dashboard – transparent nachzuvollziehen und gleichzeitig den Mehrwert eines modernen Cloud-BI-Stacks für mittelständische E-Commerce-Anbieter herauszuarbeiten. Die Arbeit demonstriert damit praxisnah, wie auch nicht-SAP-Quellen nahtlos in die SAP-Analyselandschaft integriert werden können und welche Erkenntnisse sich aus einer konsistenten Datenbasis gewinnen lassen.

¹ Corporation (2024).

² Vgl. Kimball/Ross (2002), S. 21.

2 Zielsetzung & Leitfragen

2.1 Zielsetzung

Diese Hausarbeit verfolgt das Ziel, einen durchgängigen End-to-End-Prozess zur Integration und Analyse von Online-Shop-Verkaufsdaten mit SAP Datasphere und SAP Analytics Cloud zu dokumentieren. Ausgangspunkt ist der frei verfügbare Kaggle-Datensatz "E-commerce Data", der zunächst bereinigt und in SAP Datasphere geladen wird. ³ Anschließend werden auf Basis eines dimensionalen Modells zentrale Kennzahlen (u. a. Gesamtumsatz, verkaufte Stückzahlen, durchschnittlicher Warenkorbwert) definiert, bevor sie in einem interaktiven SAC-Dashboard visualisiert und interpretiert werden. Die Arbeit soll zeigen, wie sich nicht-SAP-Quellen mit den Cloud-BI-Werkzeugen von SAP konsistent integrieren lassen und welchen geschäftlichen Mehrwert eine derart schnelle Datenaufbereitung für mittelständische E-Commerce-Anbieter bietet.

2.2 Leitfragen

Datenintegration

Wie lassen sich CSV-Verkaufsdaten in SAP Datasphere so aufbereiten, dass ein harmonisiertes, dimensionsorientiertes Datenmodell entsteht?

Kennzahlendefinition

Welche Kennzahlen eignen sich, um Umsatz, Bestellverhalten und Länderunterschiede eines Online-Shops aussagekräftig abzubilden?

Geschäftlicher Mehrwert

Welche konkreten Erkenntnisse lassen sich aus dem integrierten Dashboard ableiten, und wie unterstützen sie strategische Entscheidungen?

³ Carrie (2017).

3 Datenbasis & Angedachtes dimensionales Modell

Als empirische Grundlage dient der öffentlich verfügbare Kaggle-Datensatz "E-commerce Data.⁴ Er enthält rund 540 000 Transaktionszeilen eines britischen Online-Händlers aus den Jahren 2010–2011 und weist acht Kernspalten auf: *InvoiceNo* (Bestellnummer), *StockCode* (Artikelcode), *Description* (Artikeltext), *Quantity*, *InvoiceDate*, *Unit-Price*, *CustomerID* und *Country*. Die Daten decken damit den gesamten Bestellprozess ab – vom einzelnen Artikel bis zur zugehörigen Rechnungs- und Kundeninformation – und sind länderübergreifend (UK sowie über 30 Exportländer) erhoben.

Für die Modellierung in SAP Datasphere wird der Roh-CSV-Export zunächst lokal geprüft und bereinigt:

- **Stornobelege** (InvoiceNo beginnt mit "C") werden entfernt, ebenso Datensätze mit *Quantity* ≤ 0.
- **Fehlende Kundennummern** erhalten den Platzhalterwert "Unknown", um die Integrität der Customer-Dimension zu wahren.
- Das Zeitfeld *InvoiceDate* wird aus dem Textformat in den SQL-Date-Typ überführt.
- Per Berechnungsspalte *TotalPrice* = *Quantity* × *UnitPrice* wird der Zeilenumsatz ergänzt.

Das Datenmodell besteht aus fünf Dimensionstabellen – Product, Customer, Country, Invoice und Date – sowie dem zentralen Fact-View 267_FACT_Sales.

Die eigenständige Country-Dimension erlaubt präzise Länder-analysen (etwa UK vs. Non-UK), während die Invoice-Dimension Distinct-Kennzahlen wie Bestell-frequenz und durchschnittlichen Warenkorb performant unterstützt. Dank der klaren Stern-struktur, des hohen Transaktions-volumens und der freien Lizenz eignet sich der Datensatzoptimal, um eine End-to-End-Integration in der SAP-Cloud-BI-Umgebung zu demonstrieren.

⁴ Carrie (2017).

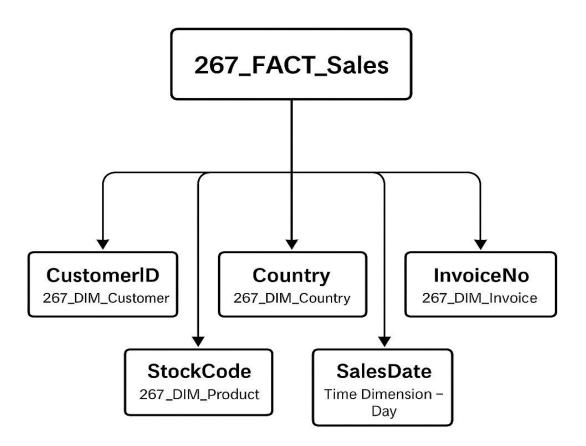


ABBILDUNG 1: ANGEDACHTES DATENMODELL⁵

⁵ Abdulhadi/*Github* (2025).

4 Methodisches Vorgehen

4.1 Datenimport & Staging

Nach einer ersten Sichtung des Kaggle-CSV-Exports werden offensichtliche Datenqualitätsprobleme (Stornobelege, negative Mengen, fehlende Kundennummern) in Excel bzw. Python bereinigt.⁶

Folgende Abbildungen werden in Excel – PowerQuery abgebildet, um dem Leser eine bessere Übersicht zu bieten.

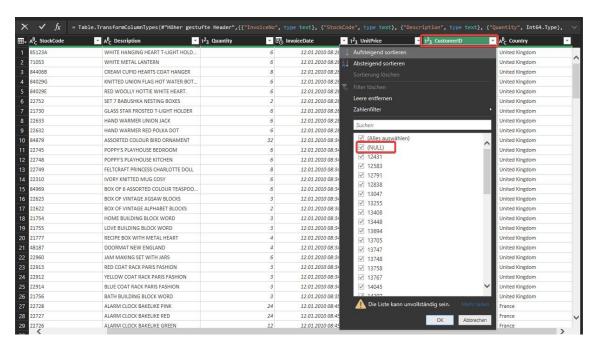


ABBILDUNG 2: DATEN UNBEARBEITET – POWERQUERY

Zur besseren Übersicht wurden aus den Datensätzen folgende Bestellnummern ausgewählt, um die Datenbereinigung nachvollziehbar darzustellen.

- 536589
- 536402
- C571196

⁶ Abdulhadi/Github (2025).



ABBILDUNG 3: FILTER - BEISPIELE

Abbildung 3 zeigt den entsprechenden Filter, der gesetzt wurde, um die nötigen Bestellungen anzuzeigen.

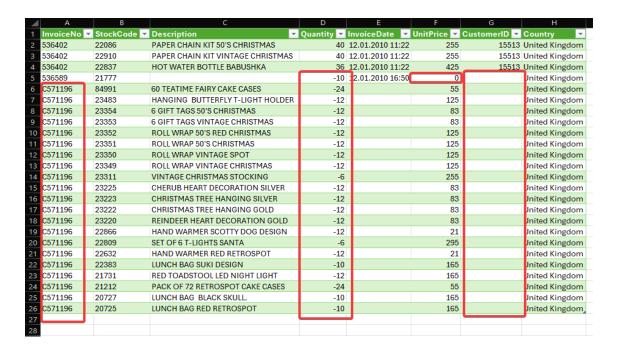


ABBILDUNG 4: UNBEREINIGTE DATEN MIT FILTER – EXCEL

Abbildung 4 zeigt stornierte Belege, fehlende CustomerIDs und stor-nierte Bestellungen. Diese müssen bereinigt werden, da stornierte Bestellungen für die benötigten Kennzahlen nicht relevant sind.

```
Datenbereinigung.py
       import pandas as pd
       from tkinter import Tk, filedialog
      root = Tk()
      root.withdraw()
      input_path = filedialog.askopenfilename(title="Wähle die CSV-Datei aus", filetypes=[("CSV-Dateien", "*.csv")])
      if not input_path:
         print("Keine Datei ausgewählt.")
      # CSV-Datei einlesen
      df = pd.read_csv(input_path, encoding="latin1")
      df = df[~df['InvoiceNo'].astype(str).str.startswith('C')]
      df['InvoiceDate'] = pd.to_datetime(df['InvoiceDate'], errors='coerce')
      output_path = filedialog.asksaveasfilename(
         title="Speicherort auswählen",
          print("Kein Speicherort ausgewählt.")
      df.to_csv(output_path, index=False)
      print(f"Datei wurde gespeichert unter: {output_path}")
```

ABBILDUNG 5: DATENBEREINIGUNGSSKRIPT - PYTHON⁷

Abbildung 5 zeigt ein Python-Skript, das zur Bereinigung von Verkaufsdaten im CSV-Format dient. Es ermöglicht die interaktive Auswahl einer Eingabedatei und eines Speicherorts für die bereinigte Ausgabedatei. Im Skript werden unter anderem folgende Schritte durchgeführt: Entfernung stornierter Belege (beginnend mit "C"), Ausschluss von Datensätzen mit nicht-positiver Menge, Ersetzung fehlender Kundennummern durch "Unknown", Umwandlung des Datumsformats sowie Berechnung eines neuen Attributs "TotalPrice". Das Skript automatisiert so zentrale Bereinigungsschritte für eine saubere Datenbasis.

⁷ Abdulhadi/*Github* (2025).

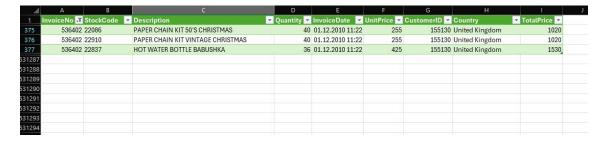


ABBILDUNG 6: BEREINIGTE DATEN MIT FILTER - EXCEL

- Die bereinigte Datei daten_bereinigt.csv wird anschließend in den zugeordneten Datasphere-Space hochgeladen.
- Während des Imports werden Datentypen vorerst als "String" belassen, um spätere Typ-Konvertierungen zentral im Data Builder vorzunehmen.

4.2 Staging-Area

Um die Tabelle in das System von Datasphere einbinden zu können und die Daten weiterverarbeiten zu können, musste die Tabelle zunächst importiert werden.

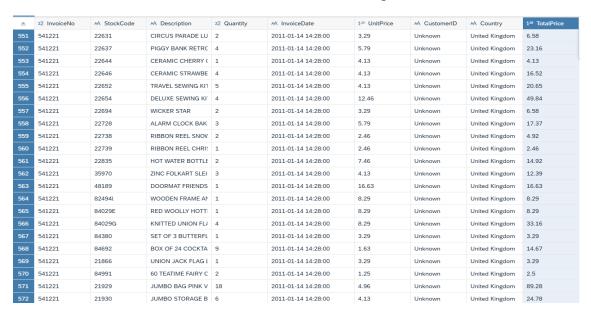


ABBILDUNG 7: IMPORTIERTE TABELLE - STAGING E-COMMERCE RAW8

Folgende Spalten wurden umbenannt:

- StockCode -> ProductID
- Description -> ProductDesc

⁸ Abdulhadi/*Github* (2025).



ABBILDUNG 8: STAGING E-COMMERCE RAW - VERZEICHNIS9

4.3 Modellierung der Dimensionen

Product-Dimension (DIM_PRODUCT)

- 1. Graphical View anlegen, Key = *ProductID*.
- 2. ProductDesc -> Semantic Type: Text & mit ProductID associated
- 3. Business & Technical Name: 267_DIM_Product



ABBILDUNG 9: PRODUCT - DIMENSION¹⁰

Customer-Dimension (DIM_CUSTOMER)\

- 1. CustomerID als Key, Country als Attribut.
- 2. Hierarchie "Country > CustomerID" definieren.

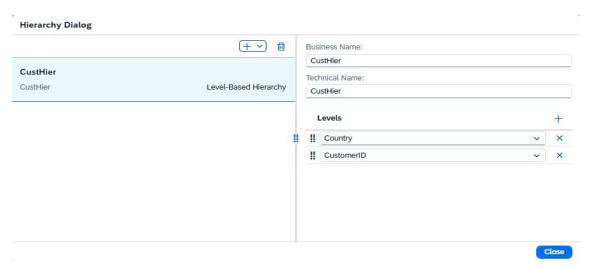


ABBILDUNG 10: HIERARCHIE-DIALOG COUNTRY-DIMENSION¹¹

¹⁰ Abdulhadi/Github (2025).

⁹ Abdulhadi/*Github* (2025).

¹¹ Abdulhadi/Github (2025).

Country-Dimension (DIM_COUNTRY)

- 1. $SQL\ View \rightarrow Projection\ nur\ auf\ Country$.
- 2. SQL Code eingeben:

SELECT DISTINCT "Country"
FROM "Staging_ECommerce_Raw"
WHERE "Country" IS NOT NULL

- 3. Key = Country.
- 4. Semantic Type = Text

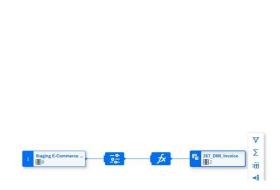
Durch das SELECT DISTINCT erhält man jede Länder-ausprägung genau einmal. Country bleibt als Schlüssel-attribut der Dimension und kann später in Zeit-, Produkt-oder Kunden-analysen gefiltert bzw. verglichen werden (z. B. UK vs. Non-UK).



Invoice-Dimension (DIM_Invoice)

- 1. *Graphical View* erstellen, Key = InvoiceNo.
- 2. Projection: InvoiceNo, InvoiceDate.
- 3. Calculated Column SalesDate = TO_DATE(CAST("SalesDate" AS VARCHAR), 'YYYY-MM-DD HH24:MI:SS')
- 4. Semantic Type:
 - InvoiceNo $\rightarrow ID$
 - SalesDate $\rightarrow Date$.

¹² Abdulhadi/Github (2025).



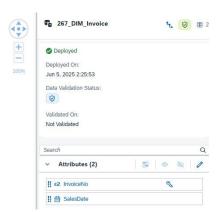


ABBILDUNG 12: INVOICE-DIMENSION¹³

4.4 Fakten-View

Schritt	Aktion	Screenschots/Codesnip	
1	Projection auf STG-Tabelle	Staging E-Commerce Staging E-Commerce Staging E-Commerce 1	
2	fx-Column <i>SalesDate</i> → TO_DATE	TO_DATE(CAST("InvoiceDate" AS VAR-CHAR), 'YYYY-MM-DD HH24:MI:SS')	
3	fx-Column <i>TotalPrice</i> → Quantity * UnitPrice	Quantity * UnitPrice	
4	Filter: Quantity > 0	Value Name * Filter 1 Expression Insert Values Validate Quantity > 0	

¹³ Abdulhadi/*Github* (2025).

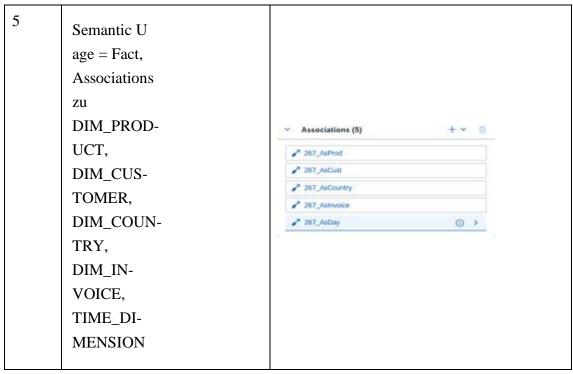


ABBILDUNG 13: ASSOCIATIONS - FACTS

4.5 Kennzahlen & Filter-Variabeln

Im Analytic Model **AM_ECOM_SALES** werden folgende Measures & Filter definiert:

NetSales	TotalPrice	Basisumsatz
ItemsSold	Quantity	Stückzahl
AvgBasket	NetSales / DISTINCT	Ø Warenkorb



ABBILDUNG 14: MEASURES - ANALYTIC MODEL¹⁴

¹⁴ Abdulhadi/*Github* (2025).

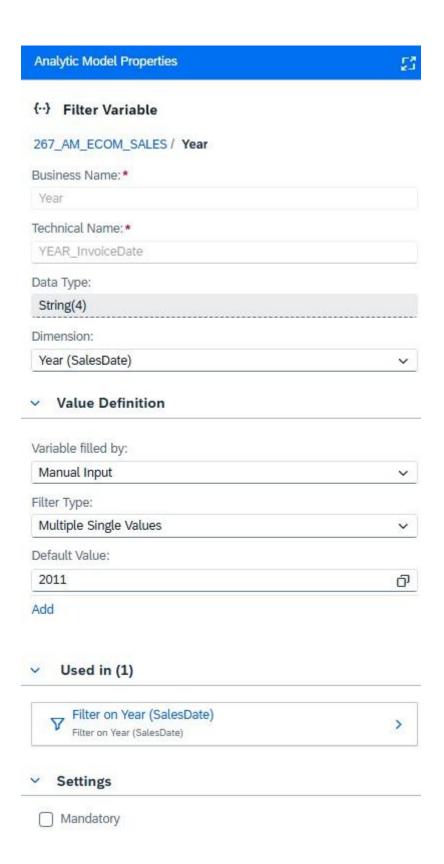


Abbildung 15: Filter - Year 15

¹⁵ Abdulhadi/Github (2025).

Insgesamt ergibt sich mit allen Dimensionen, Fakten und entsprechenden Filterungen und weiteren Modifizierungen, folgendes Datenmodell.

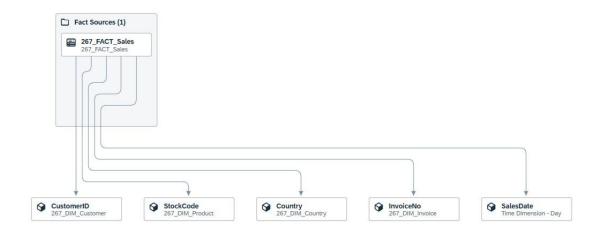


ABBILDUNG 16: DATENMODELL¹⁶

4.6 Story-Erstellung in SAP Analytics Cloud

Netto-Umsatz pro Monat (Liniendiagramm)

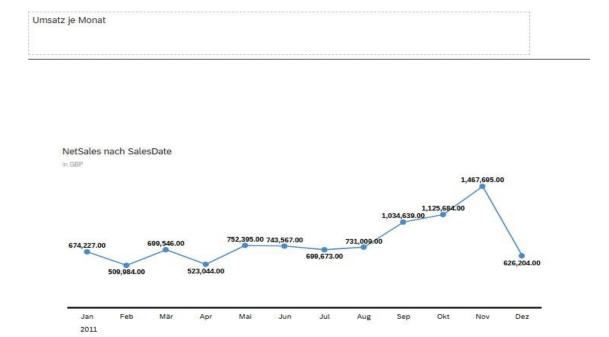


ABBILDUNG 17: NETTOUMSATZ PRO MONAT - LINIENDIAGRAMM¹⁷

Der Jahresverlauf zeigt ein typisches **Saisonmuster** für den Online-Handel:

¹⁶ Abdulhadi/Github (2025).

¹⁷ Abdulhadi/Github (2025).

- Von Januar bis August schwankt der Umsatz moderat zwischen ca. 500 k GBP und 730 k GBP.
- **September–November** steigt die Kurve deutlich an (Peak ≈ 1,47 Mio GBP) klassischer Vorweihnachts-/Black-Friday-Effekt.
- Im Dezember fällt der Umsatz zwar zurück, bleibt aber höher als im Frühjahr.
 ⇒ Das Unternehmen erzielt rund 40 % des Jahresumsatzes im letzten Quartal;
 Marketing-Budget sollte daher auf Q4 fokussiert werden.

Top 5 Meistverkaufte Produkte (Säulendiagramm)



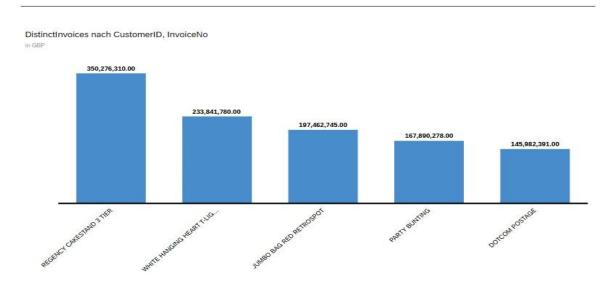


ABBILDUNG 18: TOP 5 MEISTVERKAUFTE PRODUKTE - SÄULENDIAGRAMM¹⁸

Die Balken zeigen, dass das meistverkaufte Produkt einen Umsatz von rund 390 Millionen GBP generiert – deutlich mehr als der zweitplatzierte Artikel mit 233 Millionen GBP. Damit trägt dieses eine Produkt überproportional zum Gesamtumsatz bei.

- Das Spitzenprodukt trägt > 20 % zum Gesamtumsatz der Top-5 bei ein klarer Kandidat für Preis- und Lagerbestandsoptimierung.
- Sortimentspflege sollte sich nicht nur auf den Bestseller, sondern auf die breite Umsatzbasis der Plätze 2-5 konzentrieren, da hier weiteres Potenzial bei geringerer Abhängigkeit besteht.

¹⁸ Abdulhadi/Github (2025).

Durchschnittlicher Einkaufswert nach Land (Säulendiagramm)

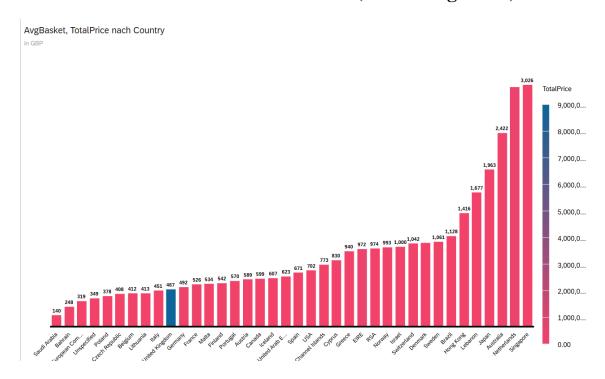


ABBILDUNG 19: DURCHSCHNITTLICHER EINKAUFSWERT NACH LAND - SÄULENDIA-GRAMM¹⁹

Hohe Clusterung: Die meisten Länder liegen zwischen 500 – 2 000 GBP Ø-Einkaufswert

- Einzelne Ausreißer (rechte Seite)
- Länder mit blau markiertem Balken (UK-Heimatmarkt) rangieren knapp im Mittelfeld kein Top-Spender, aber solide Basis.
- → Für Upselling-Strategien lohnen sich Premium-Ländergruppen (> 1,5 k GBP Ø-Basket) sowie gezielte Kampagnen, um Niedrig-performer in der linken Range anzuheben.

¹⁹ Abdulhadi/Github (2025).

5 Fazit

Die vorliegende Hausarbeit demonstriert, wie sich ein frei zugänglicher E-Commerce-Datensatz mithilfe von **SAP Datasphere** und **SAP Analytics Cloud** (SAC) in einen konsistenten Analyse-Stack überführen lässt – von der Rohdatei bis zum interaktiven Dashboard.

Im ersten Schritt wurde gezeigt, dass sich selbst heterogene CSV-Quellen nach einer verhältnismäßig schlanken Python-Vorbereinigung verlustfrei in den Cloud-Space laden lassen. Die dimensionale Modellierung (Product, Customer, Country, Invoice, Date) sowie die saubere Trennung von Fakten und Dimensionen erwiesen sich dabei als zentraler Faktor für Performance und Wiederverwendbarkeit. Durch eindeutige Semantic-Typen und Text-Associations konnten IDs automatisch mit Klartext ergänzt werden, was der späteren Berichtsqualität unmittelbar zugutekommt.

Das auf dem Fact-View basierende **Analytic Model** stellte alle notwendigen Kennzahlen – Gesamtumsatz, verkaufte Stückzahl, durchschnittlicher Warenkorb etc. – in wiederverwendbarer Form bereit. Besonders wertvoll waren dabei Variablen wie *Year*, die eine dynamische Filterung ohne zusätzliche Modellversionen ermöglichen.

Die anschließende Auswertungsphase in der SAC bestätigte die Güte des Datenmodells:

- Das Liniendiagramm zum monatlichen Umsatz offenbarte ein klares Saisonmuster mit einem massiven Peak im vierten Quartal, was datengetriebenes Budget-Shifting rechtfertigt.
- Die Top-5-Produktanalyse zeigte eine signifikante Abhängigkeit von einem einzelnen Artikel – ein konkreter Ansatzpunkt für Sortiments- und Risikomanagement.
- Die **Länderanalyse** belegte stark divergierende Warenkorbwerte und identifizierte Premium-Cluster, die sich gezielt für Upselling-Kampagnen eignen.

In Summe belegt das Projekt, dass mittelständische Online-Händler durch den Einsatz von SAP-Cloud-BI-Werkzeugen in kurzer Zeit ein belastbares, skalierbares Reporting aufbauen können – ohne tiefgreifende ABAP- oder BW-Kenntnisse. Die End-to-End-Cloud-Pipeline reduziert manuelle Aufwände, erhöht die Datenqualität und liefert Entscheidern nahezu in Echtzeit geschäftsrelevante Insights.

Literaturverzeichnis

- Abdulhadi, K./*Github* (2025): nichtkarim/BI2_Projekt, in: https://github.com/nichtkarim/BI2_Projekt, [Stand 04.06.25].
- *Carrie* (2017): E-Commerce Data, in: https://www.kaggle.com/datasets/carrie1/ecommerce-data/data, [Stand 04.06.25].
- Corporation, A. (2024): Is the On-Premises Data Warehouse Dead?, in: https://www.actian.com/blog/data-warehouse/is-the-on-premises-data-warehouse-dead/, [Stand 05.06.25].
- Kimball, R./Ross, M. (2002): The data warehouse toolkit. The complete guide to dimensional modeling, 2. Aufl., New York, NY, Weinheim.